


Para saber mais: métricas #1

Na aula sobre Regressão Logística, nós conhecemos algumas métricas para avaliar nosso modelo de machine learning. Entre elas está a **matriz de confusão**, da qual também conseguimos achar os valores de **acurácia**, **precisão**, **recall (sensibilidade)** e **F1 Score**.

A matriz de confusão é uma ferramenta muito utilizada para avaliar modelos de machine learning de classificação. Ela consiste em uma matriz em que **as linhas representam os valores reais** e **as colunas representam os valores preditos**. Cada espaço da matriz passa a ser um diagnóstico. Para nosso contexto, a ideia geral é contabilizar a quantidade de vezes que um caso de não fraude é classificado como fraude e vice-versa.

Cada um dos valores da matriz são identificados por um diagnóstico, que em ordem das linhas são:



- **Elemento na posição (0,0):** representa a quantidade de classificações **Verdadeiros Negativos**, ou seja, a quantidade de vezes que o modelo acertou a predição negativa conforme os dados reais. No exemplo, o classificador previu

corretamente 25377 casos em que o resultado foi de transações não fraudulentas.

- **Elemento na posição (0,1):** representa a quantidade de classificações **Falsos Positivos**, ou seja, a quantidade de vezes que o modelo previu incorretamente um resultado como positivo. No exemplo, o classificador previu, incorretamente, 4 casos em que o resultado foi fraude, sendo que a predição correta deveria ser de não fraude.
- **Elemento na posição (1,0):** representa a quantidade de classificações **Falsos Negativos**, ou seja, a quantidade de vezes que o modelo previu incorretamente um resultado como negativo. No exemplo, o classificador previu incorretamente 22 casos em que o resultado foi de não fraude, sendo que a predição correta deveria ser fraude.
- **Elemento na posição (1,1):** representa a quantidade de classificações **Verdadeiros Positivos**, ou seja, a quantidade de vezes que o modelo acertou a predição positiva conforme os dados reais. No exemplo, o classificador previu corretamente 1 caso em que houve fraude.

Através da identificação dos diagnósticos, é possível extrair métricas da matriz de confusão que são importantes para avaliar o quão bem o modelo está classificando os dados. As principais métricas que podem ser extraídas da matriz de confusão são:

- **Acurácia/Accuracy:** avalia a proporção de acertos em relação a todas as previsões realizadas. É obtida somando a diagonal principal da matriz e dividindo pela soma de todos os valores.

$$\text{acurácia} = \frac{VN + VP}{VN + FP + FN + VP}$$

Para o exemplo da aula, temos:

$$\text{acurácia} = \frac{25377 + 1}{25377 + 4 + 22 + 1} = \frac{25378}{25404} = 0,99897$$

- **Sensibilidade/Revocação/Recall:** avalia a proporção de verdadeiros positivos dentre todos os valores positivos reais. É obtida dividindo os verdadeiros

positivos pela soma de positivos reais.

$$\text{sensibilidade} = \frac{VP}{VP + FN}$$

Para o exemplo da aula, temos:

$$\text{sensibilidade} = \frac{1}{1 + 22} = \frac{1}{23} = 0,0434$$

- **Precisão/Precision:** avalia a proporção de verdadeiros positivos dentre as predições dadas como positivas pelo modelo. É obtida dividindo os verdadeiros positivos pela soma das previsões positivas.

$$\text{precisão} = \frac{VP}{VP + FP}$$

Para o exemplo da aula, teríamos:

$$\text{precisão} = \frac{1}{1 + 4} = \frac{1}{5} = 0,2$$

- **F1 Score:** é o equilíbrio entre a sensibilidade e a precisão, sendo a média harmônica entre as duas métricas.

$$f1 = 2 * \frac{\text{precisão} * \text{sensibilidade}}{\text{precisão} + \text{sensibilidade}}$$

Para o exemplo da aula, temos:

$$f1 = 2 * \frac{0,2 * 0,0434}{0,2 + 0,0434} = 2 * \frac{0,00868}{0,2434} = 0,0713$$